

Sviluppo e Valutazione di un Sistema di Portfolio Management Quantitativo basato su Machine Learning e Risk Parity

Report Tecnico Dettagliato

12 maggio 2026

Sommario

L'applicazione di algoritmi di Machine Learning (ML) alla gestione di portafogli finanziari rappresenta una delle frontiere più promettenti della finanza quantitativa. Il presente documento analizza in profondità l'architettura, le scelte implementative e i modelli matematici sottostanti a un framework Python proprietario (`portfolio_ml_v4.py`). Il sistema integra modelli predittivi non lineari (Random Forest, XGBoost e logiche di Ensemble) con tecniche di allocazione del capitale basate sulla parità di rischio (Risk Parity). Viene inoltre posta particolare enfasi sulla risoluzione di problematiche classiche del backtesting, quali il *look-ahead bias*, l'*overfitting* e la modellazione inaccurata dei costi operativi di ribilanciamento (*fee bleeding*).

Indice

1	Architettura di Sistema e Configurazione	3
1.1	Universo Investibile e Prevenzione del Survivorship Bias	3
1.2	Modellazione dei Costi di Transazione	3
2	Data Processing e Ingegnerizzazione delle Feature	3
2.1	Dominio Tecnico e Momentum	3
2.2	Dominio Macroeconomico	4
3	La Formulazione del Target Dinamico	4
4	Motore Predittivo e Walk-Forward Validation	4
4.1	Walk-Forward Methodology	5

5	Motore di Backtesting e Risk Parity	5
5.1	Allocazione Risk-Parity	5
5.2	Gestione del Drift e dei Ribilanciamenti	5
6	Metriche di Valutazione e Output Grafico	6
7	Conclusioni	6

1 Architettura di Sistema e Configurazione

Il framework è costruito secondo i principi dell'Object-Oriented Programming (OOP) e centralizza la parametrizzazione tramite una `dataclass Config`. Questa separazione tra configurazione e logica di esecuzione garantisce scalabilità e riproducibilità degli esperimenti.

1.1 Universo Investibile e Prevenzione del Survivorship Bias

Il sistema analizza un universo eterogeneo di 48 asset, suddivisi in tre macro-categorie (*Equity*, *Bond*, *ETF*). Un elemento di notevole spessore accademico è l'inclusione intenzionale di asset cosiddetti *distressed* o delistati (ad esempio i ticker `SIVBQ.PK` per Silicon Valley Bank o `CSGN.S` per Credit Suisse). Includere titoli falliti è un metodo empirico per mitigare il *survivorship bias* (bias di sopravvivenza) e per forzare i modelli ad apprendere i pattern tecnici e macroeconomici che precedono i crolli catastrofici.

1.2 Modellazione dei Costi di Transazione

L'impatto dei costi è gestito in modo granulare, assegnando spread in *basis points* (bps) proporzionali alla liquidità stimata dell'asset. Si va dai 5 bps per ETF iper-liquidi (es. `SPY.P`) fino ai 200 bps per le azioni *Over-The-Counter* (OTC) illiquide.

2 Data Processing e Ingegnerizzazione delle Feature

La qualità dei modelli di ML dipende indissolubilmente dallo spazio delle feature fornito in input. Il modulo di *Feature Engineering* calcola oltre 50 indicatori per ogni asset, strutturati in tre domini principali.

2.1 Dominio Tecnico e Momentum

I prezzi vengono trasformati in metriche stazionarie per facilitare l'apprendimento:

- **Trend e Momentum:** Rendimenti rolling a 5, 10, 20 e 60 giorni. Le medie mobili (SMA) vengono normalizzate come ratio rispetto al prezzo corrente, catturando le deviazioni dalla media di lungo periodo (fino a 200 giorni).
- **Oscillatori:** Il *Relative Strength Index* (RSI) e il *Moving Average Convergence Divergence* (MACD) forniscono indicazioni sulle condizioni di ipercomprato/iper-venduto.

- **Volatilità:** Le Bande di Bollinger generano due feature: la posizione del prezzo rispetto alle bande ($\%B$) e l'ampiezza delle stesse (*Bandwidth*), indicatore di espansione o contrazione della volatilità.

2.2 Dominio Macroeconomico

Il modello non opera nel vuoto, ma è contestualizzato attraverso proxy macroeconomiche:

- L'indice **VIX** viene utilizzato per determinare il regime di *risk-on* o *risk-off* del mercato azionario.
- Il **DXY** (Indice del Dollaro) e le curve dei tassi *Treasury* a 10 anni (*US10Y*) aiutano a modellare le pressioni inflazionistiche e le politiche monetarie.

3 La Formulazione del Target Dinamico

Un problema classico nel ML finanziario è la definizione della variabile dipendente y . L'uso di una soglia fissa (es. $+2\%$ per classificare un trend rialzista) risulta inadeguato in un portafoglio multi-asset: il 2% rappresenta rumore statistico per una criptovaluta, ma è un movimento estremo (coda della distribuzione) per un'obbligazione a breve termine.

Il sistema risolve questa distorsione implementando un **Targeting Dinamico basato sulla volatilità rolling**. La soglia di attivazione per un asset i al tempo t viene calcolata come:

$$Threshold_{i,t} = \sigma_{i,t}^{(20)} \times \sqrt{h} \times M \quad (1)$$

Dove $\sigma_{i,t}^{(20)}$ è la volatilità giornaliera calcolata sugli ultimi 20 giorni, h è l'orizzonte di previsione (`forward_period` = 10) e M è il moltiplicatore (`target_std_multiplier` = 0.35). Il target viene quindi discretizzato in tre classi:

- **+1 (Bullish):** Rendimento atteso $> Threshold$
- **-1 (Bearish):** Rendimento atteso $< -Threshold$
- **0 (Neutral):** Movimento laterale intra-soglia.

Ciò previene la polarizzazione permanente del modello sugli asset ad alto beta.

4 Motore Predittivo e Walk-Forward Validation

L'apprendimento è delegato a due architetture *tree-based* d'avanguardia: **Random Forest** (che riduce la varianza aggregando alberi non correlati) e **XGBoost** (che riduce il bias addestrando alberi sequenziali sugli errori dei precedenti). Un terzo modello, l'**Ensemble**, unisce le probabilità previste dai due precedenti per massimizzare la robustezza.

4.1 Walk-Forward Methodology

L'impiego della *k-fold cross-validation* è fallace in finanza perché causa *data leakage* (scambio di dati futuri e passati). Il sistema adotta una validazione *Walk-Forward* con finestra di addestramento in espansione:

1. Addestramento sui primi 504 giorni.
2. Previsione *out-of-sample* (OOS) per i successivi 21 giorni (**step.size**).
3. Avanzamento temporale, inglobando i 21 giorni appena trascorsi nel nuovo set di training.

Questo approccio, seppur computazionalmente oneroso, simula fedelmente le reali condizioni di operatività di un gestore di fondi. Il collo di bottiglia computazionale è stato abbattuto parallelizzando le computazioni attraverso la libreria *joblib*, elaborando i walk-forward di asset differenti su core multipli e riducendo il tempo di calcolo totale in modo drastico.

5 Motore di Backtesting e Risk Parity

L'ultima pipeline del sistema trasforma i segnali in una vera e propria allocazione patrimoniale, risolvendo il fondamentale problema del *fee bleeding*.

5.1 Allocazione Risk-Parity

Invece di allocare equamente il capitale tra gli asset classificati come "Bullish", l'algoritmo distribuisce il peso in base all'inverso della volatilità. Il peso teorico w_i dell'asset i è proporzionale al punteggio:

$$Score_i = \frac{Signal_i}{\sigma_{i,t}} \quad (2)$$

Ciò garantisce che asset altamente stabili ricevano capitali maggiori rispetto ad asset speculativi, stabilizzando la varianza complessiva del portafoglio (approccio concettualmente affine alla logica *All Weather* di Ray Dalio).

5.2 Gestione del Drift e dei Ribilanciamenti

I costi di transazione non vengono applicati ingenuamente al turnover teorico, ma sul delta reale tra il portafoglio *driftato* (modificato dalle oscillazioni di mercato) e il nuovo target. Inoltre, il motore esegue i trades **solo ogni 21 giorni**. Operare quotidianamente (*daily rebalancing*) avrebbe eroso la quasi totalità dei profitti netti a causa delle micro-operazioni di aggiustamento. Lasciando "correre" le posizioni per un intero mese lunare, la strategia massimizza il tasso di crescita annuo composto (CAGR).

6 Metriche di Valutazione e Output Grafico

Il sistema è corredato da una suite di reportistica quantitativa che non si limita ai rendimenti assoluti, ma valuta il profilo Rischio-Rendimento tramite parametri accademici:

- **Sharpe e Sortino Ratio:** Per valutare il rendimento aggiustato per la volatilità totale e per la sola *downside deviation*.
- **Maximum Drawdown e Calmar Ratio:** Per quantificare lo stress massimo storico sopportato dalla strategia.

Il framework esporta inoltre grafici *publication-ready*, tra cui l'Equity Curve comparativa, grafici *Underwater* per il drawdown, Heatmap mensili e un'analisi ad area dell'allocazione patrimoniale nel tempo.

7 Conclusioni

Il codice esaminato rappresenta una struttura di *Algorithmic Trading* robusta e istituzionalmente valida. Combinando target dinamici, algoritmi non lineari in ensemble e l'allocazione Risk Parity, il sistema riesce a costruire portafogli caratterizzati da una drastica riduzione del rischio storico e una volatilità profondamente inferiore rispetto al benchmark passivo azionario, posizionandosi come una valida soluzione di tipo *Absolute Return*.